

Machine Learning

Aula 20 – Introdução à redes neurais (III)

2021 – Engenharia Fábio Ayres <fabioja@insper.edu.br> · problema de ohinizaçõs: arg min L(0) · algoritmo de otimizaçõs: no de ofinizaçõs:

- Gradient descent: $\{\theta^{(i+1)} = \theta^{(i)} - \gamma \cdot \nabla L(\theta)\}$ - simples: so depende de calcular $\nabla_{\theta} L(\theta)$ Les autodiff.

www.insper.edu.br -

— Insper



-2 APIs: Sequential e Functional + simples + flexivel

rank (posto)
- Formatio dos dados: tensores -> "matrizes" n-dimensionais


- número: tensor de roul zero X: notem indice
- veter: tensor de rank 1 ~ x[i]
- matriz: tensor de rank 2 » x[i,j]
- -tensor de rank k:

x[is, i2,..., ik]

4 - Dimensoes de tensor ten significade especial: X.shape => (100, 28, 28) Capende da camada numero de amostras num batch rank 2 Exemples: · Dense: requer (batch-size, num-features) · Conv2D: requer (batch-size, linhas, columns, canais) · LSTM: (balch-size, tempo, features) Time Distributed (model): (betch-side tompo, _ -)

```
Flatten:
```

```
5
```




```
model = keras.models.Sequential([
                    keras.layers.Flatten(input_shape=[28, 28]),
                  → keras.layers.Dense(300, activation="relu"),
                    keras.layers.Dense(100, activation="relu"),
                    keras.layers.Dense(10, activation="softmax"),
                ])
                 784 = 28 x 23
                                                          300
                                    Derse (300)
batch_size
                                                                  Insper
www.insper.edu.br
```

```
7
```

```
Vense:
```

```
model = keras.models.Sequential([
    keras.layers.Flatten(input_shape=[28, 28]),
    keras.layers.Dense(300, activation="relu"),
    keras.layers.Dense(100, activation="relu"),
    keras.layers.Dense(10, activation="softmax"),
])
```




- Insper

Model: "sequential"

Layer (type)	Output Shape	Param #
flatten (Flatten)	(None, 784)	0
dense (Dense)	(None, 300)	235500
dense_1 (Dense)	(None, 100)	30100
dense_2 (Dense)	(None, 10)	1010

Total params: 266,610 Trainable params: 266,610 Non-trainable params: 0


Cade neuronio:




nspe

```
9
```

```
input_ = keras.layers.Input(shape=X_train.shape[1:])
hidden1 = keras.layers.Dense(30, activation="relu")(input_)
hidden2 = keras.layers.Dense(30, activation="relu")(hidden1)
concat = keras.layers.concatenate([input_, hidden2])
output = keras.layers.Dense(1)(concat)
model = keras.models.Model(inputs=[input_], outputs=[output])
```



Neurônio artificial




Funções de ativação


- Conferem o carater n\u00e4o-linear da rede neural
 - Senão seria apenas uma transformação afim (linear + constante)
- Algumas funções comuns:
 - Função identidade: para quando não queremos a nãolinearidade mesmo
 - Anos 60: Degrau e sinal
 - Anos 80: Sigmoides logistica e tangente hiperbólica
 - Anos 2000: Rectified linear units relu, elu, selu, gelu, etc...



Função degrau (Heaviside)

- Trivial de calcular
- Problema: a derivada é inútil (este problema aparece muito nas redes neurais modernas!)







www.ins

⁴...≲þer

Função sinal


- Trivial de calcular
- Mesmo problema da derivada nula







Função logística







Função logística

$$f(x) = \frac{1}{1 + e^{-x}}$$

- Contínua e derivável
- Pesada para calcular
- Não sofre de descontinuidade na derivada
- Sofre do problema das derivadas quase-nulas longe da origem

Função tangente hiperbólica









Função tangente hiperbólica

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- Contínua e derivável
- Pesada para calcular
- Não sofre de descontinuidade na derivada
- Também sofre do problema das derivadas quasenulas longe da origem

Rectified linear unit






Rectified linear unit (relu)


$$f(x) = f(x) = \begin{cases} x, & x \ge 0 \\ 0, & x < 0 \end{cases}$$

- Trivial de calcular
- Sofre de derivadas nulas apenas de um lado (isso já ajuda)
- Sofre de descontinuidade na derivada
 - Isso pode fazer o gradient descent ficar "oscilando" perto da origem!



Leaky relu








Leaky relu

$$f(x) = f(x) = \begin{cases} \alpha x, & x < 0 \\ x, & x \ge 0 \end{cases}$$

- Trivial de calcular
- Não tem derivadas nulas
- Sofre de descontinuidade na derivada

Exponential linear unit (elu)








Exponential linear unit (elu)

$$f(x) = f(x) = \begin{cases} \alpha(e^x - 1), & x < 0 \\ x, & x \ge 0 \end{cases}$$

- Pesado de calcular
- Não tem derivadas nulas
 - Mas longe da origem a derivada é quase-nula
- Se $\alpha = 1$ não sofre de descontinuidade na derivada


Camada (layer) de neurônios

"Fully-connected layer"




Camada de neuronios

• Geralmente representada de modo simples:



Rede neural multicamadas





Softmax

